

Projet Statistique 2
Mehdi Sauvage

December 8, 2016

1 Estimation

(a)

Pour chaque échantillons iid, le calcul de la variance et su biais pour la moyenne des échantillons a été exécuté comme définit ci-dessous.

Définition de la variance :

$$V(m_x) = E [(m_x - E(m_x))^2]$$

Définition du biais:

$$B(m_x) = |E(m_x) - \mu|$$

Dans le cas des 100 échantillons de 20 étudiants, la variance vaut 0.340 et le biais est égal à 0.16.

(b)

Définition de la variance :

$$V(med_x) = E [(med_x - E(med_x))^2]$$

Définition du biais:

$$B(med_x) = |E(med_x) - \mu|$$

Dans le cas des 100 échantillons de 20 étudiants, la variance vaut 0.499 et le biais est égal à 0.276.

(c)

Considèreront le cas ou les échantillons sont de tailles 50. Il en suit une variation de la variance et du biais. en effet,

X	échantillons 20	échantillons 50
$V(m_x)$	0.16	0.1141
$B(m_x)$	0.1666	0.0049
$V(med_x)$	0.4899	0.2177
$B(med_x)$	0.3809	0.2742

Nous pouvons constater que l'augmentation de la taille des échantillons fait diminuer toutes les valeurs de biais et de variance. Intuitivement, cela a du sens d'imaginer que en augmentant l'information contenue dans chaque échantillons, nous nous rapprochons des valeurs réelles de la population.

Notons, que le biais des moyennes tendra vers la moyenne de la population alors que le biais de la médiane ne tendra pas indéfiniment vers la médiane de la population.

(d)

d.i - Loi de Student

L'intervalle de confiance se calcule comme suit :

$$m_x - t_{1-\alpha/2} \frac{s_{n-1}}{\sqrt{n}} < x < m_x + t_{1-\alpha/2} \frac{s_{n-1}}{\sqrt{n}}$$

Notons que la valeur de $t_{1-\alpha/2}$ se trouve dans les tables.

d.ii - Loi de Gauss

L'intervalle de confiance se calcule comme suit :

$$m_x - u_{\alpha/2} \frac{\sigma}{\sqrt{n}} < x < m_x + u_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

Notons que la valeur de $u_{\alpha/2}$ se trouve dans les tables.

d. - Explications

Le nombre de degrés de liberté dans les deux cas est $n - 1$ soit 19. De plus, nous remarquons que les résultat donnée par la loi Student et la loi de Gauss sont fort similaire.

En effet, la théorie dit que pour des échantillons suffisamment grand, les intervalles se confond de plus en plus ($n > 30$). Le cas ou $n = 20$ n'étant pas très éloigné, la similitude entre les résultat semble cohérent.

La moyenne de la population a été comprise 96 fois sur 100 dans les intervalles généré. Nous remarquons que cette valeur est proche de $1 - \alpha$.

2 Test d'hypothèse

Soit les deux hypothèse H_0 et H_1 définit comme suit:

- H_0 : "un quart des étudiants ont obtenu une note inférieur à 10 et l'hypothèse alternative"
- H_1 : "plus d'un quart des étudiants ont obtenu une note inférieur à 10"

Nous supposons que f , un estimateur des résultats des étudiants, est une variable qui suit une loi normale.

$$f \sim \mathcal{N} \left(p, \left(\sqrt{\frac{p(1-p)}{n}} \right)^2 \right) = 1 - \alpha$$

ou p étant la proportion d'étudiant avec une moyenne ≥ 10 .

il faut déterminer ϵ tel que l'intervalle pour H_0 ait des valeurs de f favorable.

$$P(f \leq p + \epsilon) = 1 - \alpha$$

$$\Leftrightarrow P(f \leq 0.25 + \epsilon) = 0.95$$

En exprimant la loi de Gauss sous la forme centrée réduite, nous obtenons

$$P\left(Z \leq \frac{\epsilon}{\sigma}\right) = 0.95$$

Pour trouver $\epsilon = 0.1598$ nous devons chercher dans la table de gauss.

(a)

L'ULg rejette l'hypothèse que au moins un quart des étudiants ait obtenu une note finale $\geq 10/20$ dans 4 cas. Notez que le nombre de cas de rejet s'approche de la valeur de α .

(b)

Les instituts de sondage rejettent l'hypothèse que au moins un quart des étudiants ait obtenu une note finale $\geq 10/20$ dans 19 cas. Notez que le nombre de cas où l'hypothèse est rejetée est plus importante que dans pour les autorités de l'ULg. Ceci est dû au fait que les instituts de sondage sont plus nombreux et on donc plus de chances de se trouver face à un échantillon à rejeter.

(c)

Pour minimiser l'influence du problème énoncé au point (c) nous pouvons donner le même échantillon à tous les instituts de sondage. Nous pourrions aussi alléger les conditions de rejet pour les instituts de sondage en diminuant α . Notons aussi qu'en augmentant le nombre d'étudiant par échantillon, les instituts de sondage (tout comme les autorités de l'ULg) seraient aussi moins souvent confrontés au rejet de l'hypothèse H_0 .

Code

```
1  function [biais_mx , var_mx] = Q1a( ech , mean_pop ,  
    var_pop )  
2  
3      %Definition de la taille de l'échantillon  
4      size_n = size(ech(1,:));  
5      n = size_n(2);  
6  
7      mean_ech_n = zeros(100,1);  
8  
9      %Calcul des moyennes des échantillons  
10     for i = 1 : 100  
11         mean_ech_n(i) = mean(ech(i,:));  
12     end  
13     %Moyenne des moyennes  
14     mean_mean_ech_n = mean(mean_ech_n(:));  
15  
16     %Calcul de la variance  
17     var_mx = var(mean_ech_n);  
18  
19     %Calcul du biais  
20     biais_mx = mean_mean_ech_n - mean_pop ;  
21  
22 end
```

```

1  function [biais_medx , var_medx] = Q1b( ech , mean_pop ,
    var_pop )
2
3  %Definition de la taille de l'échantillon
4  size_n = size(ech(1,:));
5  n = size_n(2);
6
7  med_ech_n = zeros(100 , 1);
8
9  %Calcul des medianes des échantillons
10 for i = 1 : 100
11     med_ech_n(i) = median(ech(i,:));
12 end
13
14
15 %Calcul de la moyenne des medianes
16 mean_med_ech_n = mean(med_ech_n(:));
17
18 %Calcul de la variance
19 var_medx = var(med_ech_n);
20
21 %Calcul du biais
22 biais_medx = mean_med_ech_n - mean_pop ;
23
24 end

```

```

1  function [borne_inf_norm ,borne_sup_norm ,borne_inf_stud
    ,borne_sup_stud ,stud ,norm] ...
2      = Q1d(ech , mean_pop)
3
4      %Definition de la taille de l'échantillon et
        initialisations
5      size_tmp = size(ech(1,:));
6      n = size_tmp(2);
7
8      borne_inf_norm = zeros(1,n);
9      borne_sup_norm = zeros(1,n);
10     borne_inf_stud = zeros(1,n);
11     borne_sup_stud = zeros(1,n);
12
13     mean_ech_n = zeros(n,1);
14     ET_ech_n = zeros(n,1);
15
16     stud = 0;
17     norm = 0;
18
19     for i = 1 : 100
20
21         mean_ech_n(i) = mean(ech(i,:));
22         ET_ech_n(i) = std(ech(i,:));
23
24         %Lois Normal - calcul des bornes de l'ic
25         borne_inf_norm(i) = mean_ech_n(i) - 1.96 * (
            ET_ech_n(i) / sqrt(n));
26         borne_sup_norm(i) = mean_ech_n(i) + 1.96 * (
            ET_ech_n(i) / sqrt(n));
27
28         %Loi student - calcul des bornes de l'ic
29         k = 2.093;
30         s_n_1 = sqrt(n / (n -1)) * ET_ech_n(i) ;
31
32         borne_inf_stud(i) = mean_ech_n(i) - k * (s_n_1 /
            sqrt(n));
33         borne_sup_stud(i) =mean_ech_n(i) + k * (s_n_1 /
            sqrt(n));
34
35
36         %Verification des ic avec la moyenne de la
            population
37         if ( mean_pop > borne_inf_stud(i) && mean_pop <
            borne_sup_stud(i))
38             stud = stud + 1;
39     end
40
41     if ( mean_pop > borne_inf_norm(i) && mean_pop <
        borne_sup_norm(i))

```

```

42         norm = norm + 1;
43     end
44
45 end
46
47 end

1 function [ulg_rejet , ulg_mean] = Q2a(ech)
2
3 %initialisation de la borne suprieur
4 eps = 0.1598;
5 sup = eps + 0.25;
6
7 ulg_mean = zeros(100,1);
8 ulg_rejet = 0;
9
10 for i = 1 : 100
11     for j = 1 : 20
12         %verif condition d'hypothese ( < 10 )
13         if(ech(i,1,j) < 10)
14             ulg_mean(i) = ulg_mean(i) + 1;
15         end
16     end
17
18     %calcul de la proportion de cas <10
19     ulg_mean(i) = ulg_mean(i)/20;
20
21     %calcul de la proportion de cas rejet
22     if (ulg_mean(i) > sup)
23         ulg_rejet = ulg_rejet + 1;
24     end
25 end
26
27 end

```



```

1  function [inst_rejet_ , inst_mean] = Q2b(ech)
2
3  %initialisation de la borne suprieur
4  eps = 0.1598;
5  sup = eps + 0.25;
6
7  inst_mean = zeros(100,6);
8  inst_rejet = zeros(100,1);
9
10 for i = 1 : 100
11     for j = 2 : 6
12         for k = 1 : 20
13             %verif condition d'hypothese ( < 10 )
14             if(ech(i,j,k) < 10)
15                 inst_mean(i , j) = inst_mean(i,j) + 1;
16             end
17         end
18     end
19     inst_mean(i,j) = inst_mean(i,j)/20;
20
21     if (inst_mean(i,j) > sup)
22         inst_rejet(i) = 1;
23     end
24     inst_rejet_ = mean(inst_rejet) * 100;
25 end
26
27 end

```